# Алгоритмы и структуры данных

СОРТИРОВКА. ЧАСТЬ 2

УЛУЧШЕННЫЕ СОРТИРОВКИ. ВНЕШНИЕ СОРТИРОВКИ

Сортировка - процесс перегруппировки элементов в определенном порядке.

Цель - облегчить последующий поиск элементов в отсортированном множестве.

Выбор алгоритма зависит от структуры обрабатываемых данных:

Внутренняя – для массивов (быстрая память, прямой доступ к элементам)

Внешняя – для файлов (более медленная, но и более емкая внешняя память)

#### Понятия и обозначения:

#### Если есть элементы

то сортировка есть перестановка этих элементов в массив, так что  $a[k1], a[k2], a[k3] \dots a[kN],$ 

где при некоторой <mark>упорядочивающей функции f</mark> выполняются отношения  $f(a[k1]) \le f(a[k2]) \le f(a[k3]) \le \dots \le f(a[kN])$ 

•

Обычно,

Ключ каждого элемента не вычисляется, а хранится как явная компонента (поле)

Для простоты будем учитывать только на ключ, сопутствующую информацию будем опускать

#### Сортировка массивов

Одно из основных условий — экономное использование доступной памяти, перестановки, приводящие элементы в порядок, должны выполняться на том же месте.

Метод сортировки будем называть устойчивым,

если в процессе сортировки относительное расположение элементов с равными ключами не изменяется.

Общие понятия

#### Обозначения:

N – число сортируемых элементов

С – число необходимых сравнений

М – число перестановок (пересылок) элементов

•

# Сортировка

- 1. Прямые (сортировка по методу вставок, по методу выбора, простыми обменами) O(n\*n)
- 2. Особые (сортировка подсчетом, поразрядная сортировка, карманная сортировка) O(n)

#### 3. Улучшенные сортировки

- 3.1 Сортировка Шелла
- 3.2 Пирамидальная сортировка
- 3.3 Быстрая сортировка
- 3.4 Сортировка Introsort
- 3.4 Сортировка слиянием
- 3.5 Сортировка деревом
- 3.6 Сортировка Timsort

#### 4. Внешние сортировки

- 4.1 Сортировка простым слиянием
- 4.2 Сортировка естественным слиянием

Общие понятия

## Улучшенные методы (n \* log n):

Пирамидальная сортировка

Быстрая сортировка

Сортировка Шелла

•

3.1 Сортировка Шелла

Эффективность метода Шелла объясняется тем, что сдвигаемые элементы быстро попадают на нужные места.

Среднее время для сортировки Шелла равняется  $O(n^{1.25})$ , для худшего случая оценкой является  $O(n^{1.5})$ .

# 3.2 Пирамидальная сортировка

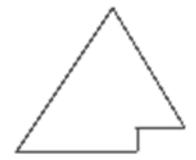
- 3.2.1 Пирамида (binary heap)
- 3.2.2 Поддержка свойств пирамиды
- 3.2.3 Построение пирамиды
- 3.2.4 Пирамидальная сортировка
- 3.2.5 Очереди с приоритетами

## 3.2.1 Пирамида

Пирамида(heap) - бинарное дерево высоты k, в котором

- все узлы имеют глубину k или k-1 дерево сбалансированное.
- при этом уровень k-1 полностью заполнен, а уровень k заполнен слева направо,
- выполняется "свойство пирамиды"

Форма пирамиды имеет приблизительно такой вид:



Два вида бинарных пирамид: невозрастающие и неубывающие

Свойство невозрастающих пирамид (max-heap property):

Для каждого узла (кроме корня) значение узла не больше значения родительского узла =>

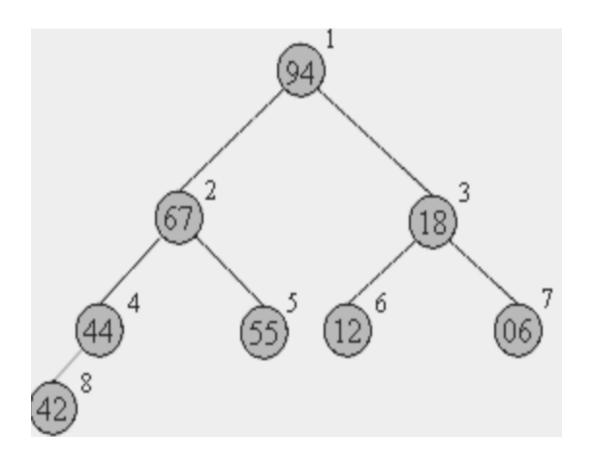
Корень – наибольший элемент

Свойство неубывающих пирамид (min-heap property):

Для каждого узла (кроме корня) значение узла не меньше значения родительского узла =>

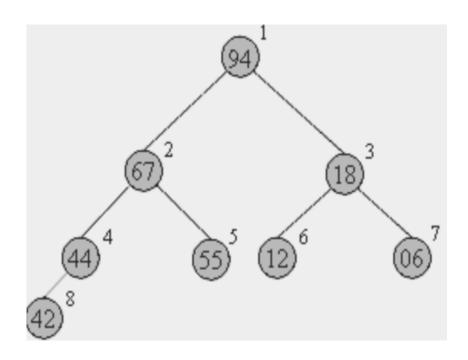
Корень – наименьший элемент

*Невозрастающая* пирамида (max-heap) , представленная в виде бинарного дерева:



```
Как хранить пирамиду? Поместим ее в массив - A [1..length[A]]
A[1] — корень дерева
A[2] — левый дочерний узел корня
А[3] – правый дочерний узел корня
Если і – индекс узла,
Parent (i) // индекс родительского узла
 return i / 2
Left (i) // индекс левого дочернего узла
return 2 * i
Right (i) // индекс правого дочернего узла
return 2 * i +1
```

*Невозрастающая* пирамида (*max-heap*), представленная в виде бинарного дерева:



Пирамида (*max-heap*), представленная в виде массива:

94 <mark>67 18 44 55 12 06 </mark>42

#### Плюсы хранения пирамиды в массиве:

- никаких дополнительных переменных, нужно лишь понимать схему
- узлы хранятся от вершины и далее вниз, уровень за уровнем
- узлы одного уровня хранятся в массиве слева направо

Для записи в виде массива пирамиду надо обойти дерево по уровням сверху-вниз.

Восстановить пирамиду из массива как геометрический объект легко - достаточно вспомнить схему хранения и нарисовать, начиная от корня

Пирамида – объект-массив,

который рассматривается как почти полное двоичное дерево.

Рассматриваем только невозрастающие пирамиды (тах-heap):

Для каждого узла (кроме корня) с индексом і выполняется:

A[ Parent(i) ] >= A[ i ]

Значение узла не превосходит значение родительского узла =>

Корень – наибольший элемент

Пирамида – объект-массив:

Высота пирамиды определяется как высота двоичного дерева (количество рёбер в самом длинном простом пути, соединяющем корень пирамиды с одним из её листьев).

Пирамида - <u>Двоичная куча</u> - Сортирующее дерево

Биномиальная куча, Фибоначчиева куча

# 3.2.2 Поддержка свойств пирамиды (невозрастающей)

Процедура *МАХ\_НЕАРІҒҮ*:

Вход – массив А, индекс і

Предполагается,

что деревья с корнями A[Left (i)] и A[Right (i)] – уже *max-heap*,

НО А[і] может быть меньше своих дочерних элементов.

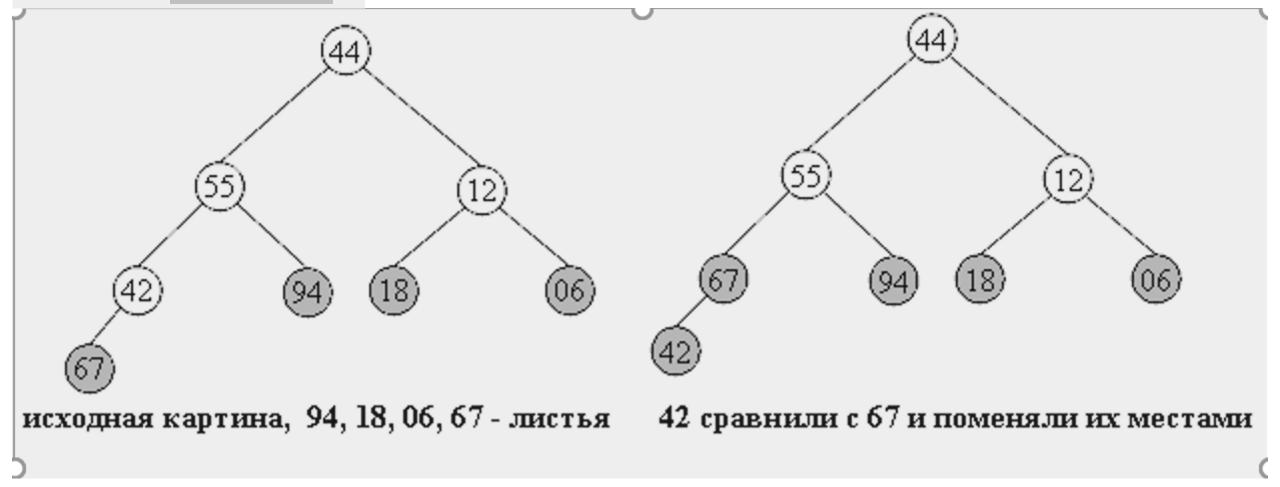
Процедура восстанавливает свойство упорядоченности во всём поддереве, корнем которого является элемент A[i].

Время работы  $- O(\ln n)$ 

#### 3.2.2 Поддержка свойств пирамиды

Процесс построения пирамиды

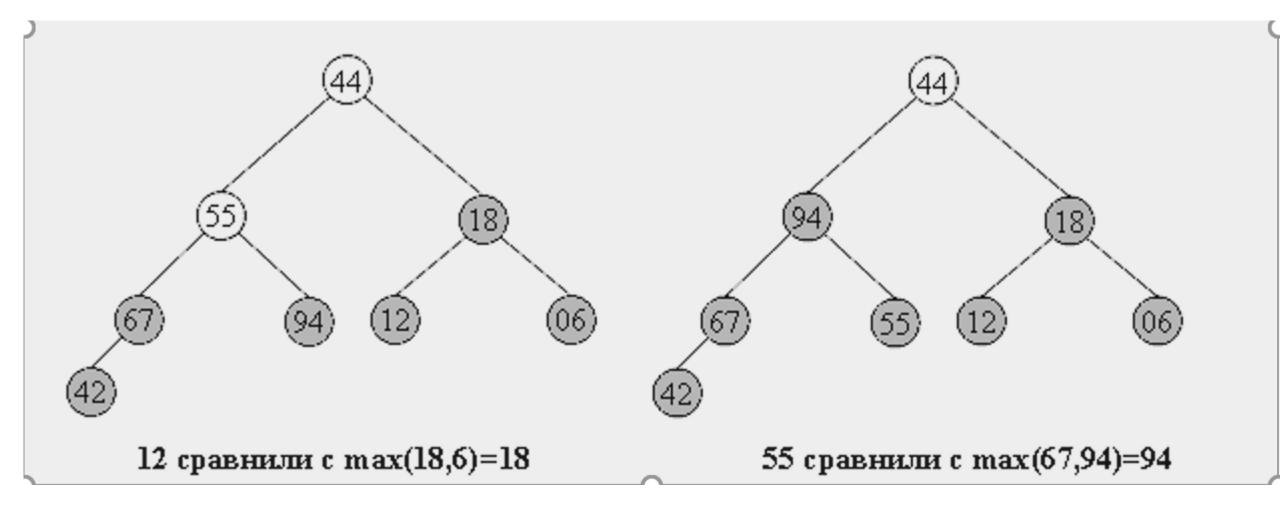
Начало массива (неготовая часть пирамиды) окрашена в белый цвет, конец массива, удовлетворяющий свойству пирамиды, - в темный.



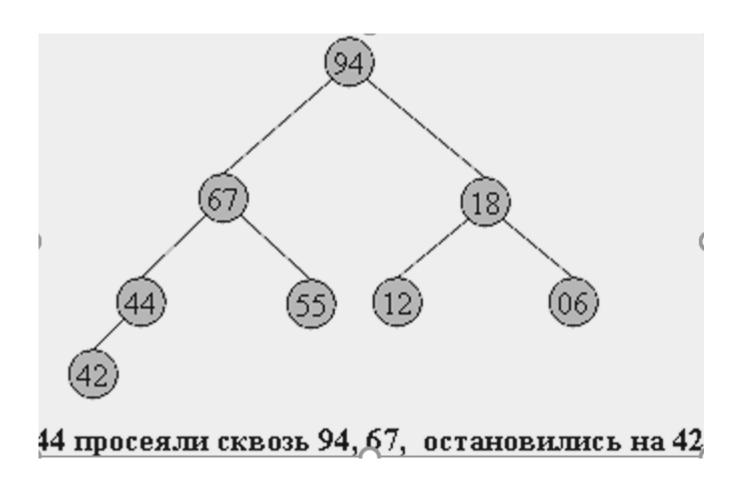
44 55 12 <mark>42 94 18 06 67</mark>

44 55 <mark>12 67 94 18 06 42</mark>

#### 3.2.2 Поддержка свойств пирамиды



44 <mark>94 18</mark> 67 67 55 12 06 42



94 67 18 44 55 12 06 42

3.2.2 Поддержка свойств пирамиды

Восстановление свойства упорядоченности во всём поддереве, корнем которого является элемент A[i]:

Если і-й элемент больше, чем его дочерние, всё поддерево уже является пирамидой (делать ничего не надо).

В противном случае меняем местами i-й элемент с наибольшим из его дочерних, после чего выполняем *Max\_Heapify* для этого дочернего.

### MAX\_HEAPIFY(A, i) ► heap\_size - количество элементов в куче

- 1. left  $\leftarrow$  2i
- 2. right  $\leftarrow$  2i+1
- 3. largest  $\leftarrow$  i
- 4. if left ≤ heap\_size [A] and A[left] > A[largest] then
- 5.  $largest \leftarrow left$
- 6. **end if**
- 7. **if** right ≤ heap\_size [A] **and** A[right] > A[largest] **then**
- 8.  $largest \leftarrow right$
- 9. end if
- 10. **if** largest ≠ i **then**
- 11 Обменять  $A[i] \leftrightarrow A[largest]$
- 12. MAX\_HEAPIFY (A, largest)
- 13. end if

# 3.2.3 Построение пирамиды

Создание пирамиды из неупорядоченного массива входных данных

Если выполнить MAX\_HEAPIFY для всех элементов массива A, начиная с последнего и кончая первым, он станет пирамидой.

#### По индукции:

к моменту выполнения MAX\_HEAPIFY (A, i) все поддеревья, чьи корни имеют индекс больше i,-пирамиды.

→ после выполнения MAX\_HEAPIFY (A, i) пирамидой будут все поддеревья, чьи корни имеют индекс, не меньший i.

MAX\_HEAPIFY(A,i) не делает ничего, если i>n/2 (при нумерации с первого элемента), где n — количество элементов массива. (у таких элементов нет потомков => соответствующие поддеревья уже являются пирамидами, так как содержат всего один элемент).

→достаточно вызвать MAX\_HEAPIFY для всех элементов массива А, начиная (при нумерации с первого элемента) с n/2 -го и кончая первым.

#### BUILD\_MAX\_HEAP(A)

- 1. heap\_size [A]  $\leftarrow$  length [A]
- 2. for  $i \leftarrow |length [A]/2| downto 1 do$
- 3. MAX\_HEAPIFY (A, i)
- 4. end for

Здесь происходит n/2 вызовов функции MAX\_HEAPIFY со сложностью O(ln n) => время работы алгоритма - O(n ln n)

НО чаще всего функция MAX\_HEAPIFY вызывается для деревьев маленькой глубины, можно показать, что время работы BUILD\_MAX\_HEAP равно O(n)

## 3.2.4 Пирамидальная сортировка

Процедура HEAPSORT сортирует массив без привлечения дополнительной памяти за время O(n ln n).

Метод *не является устойчивым*: по ходу работы массив так "перетряхивается", что исходный порядок элементов может измениться случайным образом.

Поведение неественно: частичная упорядоченность массива никак не учитывается

#### Обозначения:

А – массив-пирамида

A [ 1 . . length[A] ]

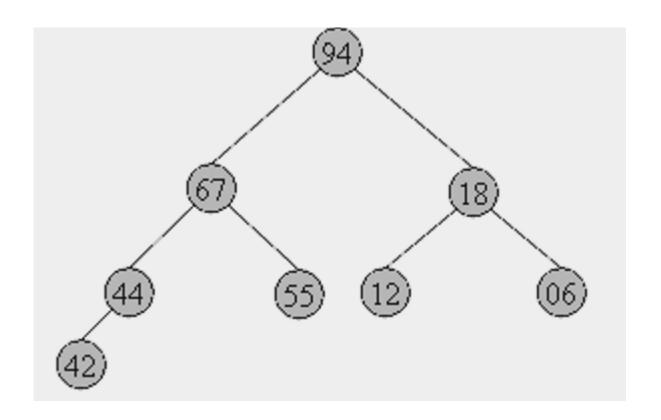
length[A] – количество элементов массива

heap\_size[A] – количество элементов пирамиды, содержащихся в массиве

A [ 1 . . heap\_size[A] ] - элементы пирамиды

A [ heap\_size[A]+1 . . length[A] ] - не элементы пирамиды

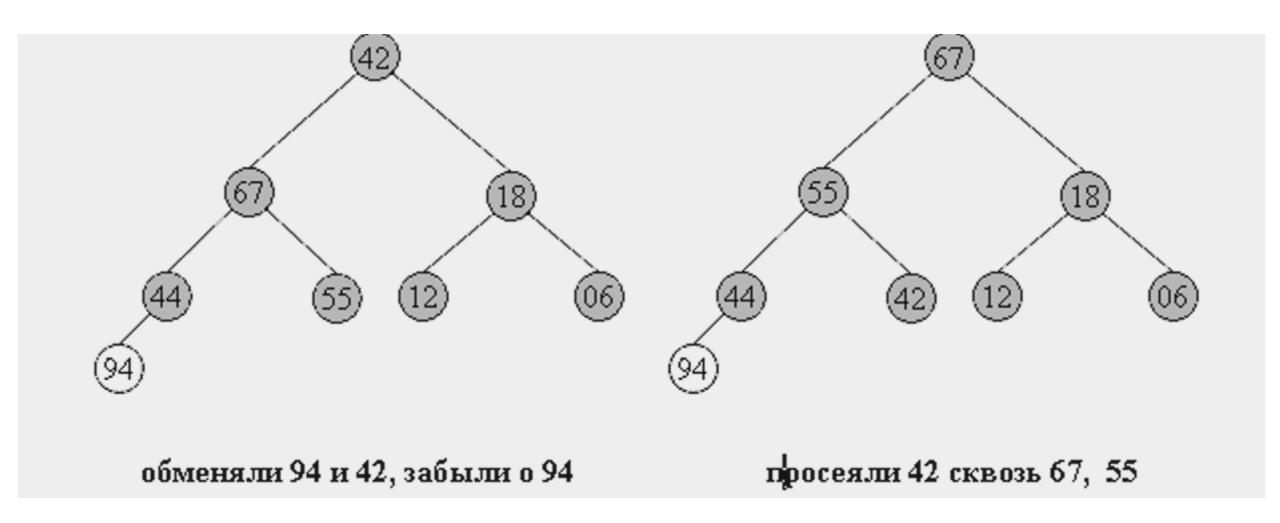
## Пирамида построена:



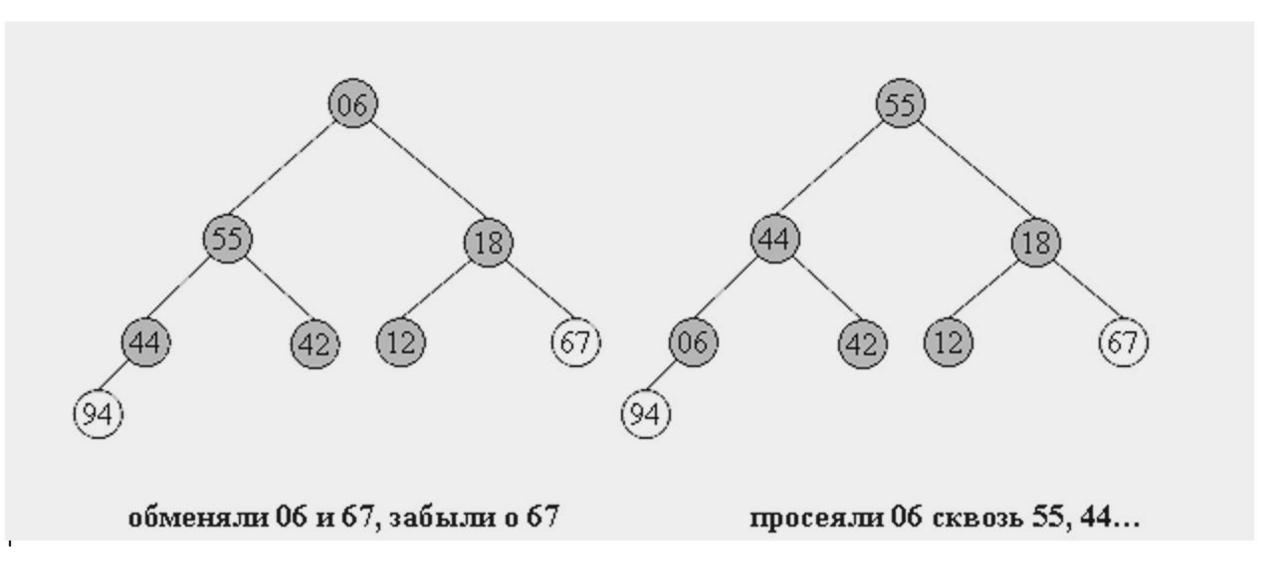
#### Пирамида построена (первый раз): $heap\_size[A] = length[A]$

- 1. Поменяем первый элемент (то есть корень) с последним элементом ==> последний элемент станет самым большим.
- 2. Исключим последний элемент из пирамиды (то есть формально уменьшим её длину heap\_size[A] на 1),
- 3. Первые *heap\_size[A]* элементов будут удовлетворять условиям пирамиды все, за исключением, может быть, корня.
- 4. Вызовем Heapify, первые *heap\_size[A]* элементов станут пирамидой.
- 5. Повторяя эти действия *length[A] -1* раз, мы отсортируем массив.

#### 3.2.3 Построение пирамиды



#### 3.2.3 Построение пирамиды



#### HEAPSORT(A)

- 1. BUILD\_MAX\_HEAP(A)
- 2. **for**  $i \leftarrow length[A]$  **downto** 1 **do**
- 3. Обменять  $A[1] \leftrightarrow A[i]$
- 4. heap\_size [A]  $\leftarrow$  heap\_size [A]-1
- 5. MAX\_HEAPIFY(A,1)
- 6. end for

Процедура HEAPSORT сортирует массив без привлечения дополнительной памяти за время O(n ln n), т.к.

Вызов BUILD\_MAX\_HEAP(A) – O(n),

Каждый из n вызовов MAX\_HEAPIFY- O(In n).

# 3.2.5 Очереди с приоритетами

Два типа: невозрастающие и неубывающие.

Реализация невозрастающих очередей с приоритетами на основе невозрастающих пирамид.

**Очередь с приоритетами** (priority queue) — структура данных, предназначенная для обслуживание множества S, с каждым элементов которого связано определенное значение, называемое *ключом* (key).

### Операции невозрастающей очереди с приоритетами:

INSERT (S,x) - вставить элемент x в множество S

MAXIMUM(S) - возвратить элемент множества S с наибольшим ключом

EXTRACT\_MAX(S) - возвратить элемент множества S с наибольшим ключом и удалить его из множества

INCREASE\_KEY(S,x,k) - увеличить значения ключа элемента x, путем замены его на ключ k (величина k не меньше текущего значения ключа x)

▶ возвратить элемент множества S с наибольшим ключом

### HEAP\_ MAXIMUM (A)

- 1. **if** heap\_size[A] < 1 **then**
- 2. error "очередь пуста"
- 3. else
- 4. return A[1]
- 5. end if

▶ возвратить элемент множества S с наибольшим ключом и удалить его

### HEAP\_EXTRACT\_MAX(A)

- 1. **if** heap\_size[A] < 1 **then**
- 2. error "очередь пуста" ▶ выход из функции
- 3.  $\max \leftarrow A[1]$
- 4.  $A[1] \leftarrow A[heap\_size[A]]$
- 6. heap\_size[A]  $\leftarrow$  heap\_size[A] 1
- 7. MAX\_HEAPIFY(A,1)
- 8. **return** max

- ▶ увеличить значения ключа элемента і, путем замены его на ключ кеу
- ▶ величина key не меньше текущего значения ключа записи і A[i]

### HEAP\_ INCREASE\_KEY( A, i, key )

- 1. **If** key < A[i] **then**
- 2. **error** "новый ключ меньше текущего" ▶ выход из функции
- 3.  $A[i] \leftarrow key$
- 4. **while** i > 1 **and** A[Parent(i)] < A[i] **do**
- 5. обменять  $A[i] \leftrightarrow A[Parent(i)]$
- 6. i← Parent(i)
- 7. end do

▶ вставить элемент с ключом кеу в множество

```
MAX_HEAP_INSERT ( A, key )

heap_size[A] ← heap_size[A] + 1

A[heap_size[A]] ← - ∞

HEAP_INCREASE_KEY(A, heap_size[A], key )
```

Операция	Время выполнения
HEAP_ MAXIMUM (A)	θ (1)
HEAP_ EXTRACT_MAX (A)	O(ln n)
HEAP_INCREASE_KEY (A,i,key)	O(ln n)
MAX_HEAP_INSERT (A,key)	O(ln n)

#### STL C++:

контейнер priority\_queue,

шаблоны функций для управления кучей make\_heap, push\_heap и pop\_heap (бинарные кучи).

# 3.3 Быстрая сортировка.

Метод декомпозиции («разделяй и властвуй»)

Быстрая сортировка", разработана более 40 лет назад, является наиболее широко применяемым и одним их самых эффективных алгоритмов.

3.3 Быстрая сортировка

Рассмотрим сортировку подмассива A[p..r].

Подход «разделяй и властвуй» - решение будет состоять из следующих этапов:

- Разделение.
- Покорение.
- Комбинирование

#### Разделение.

Массив A[p..r] разбивается на два (возможно, пустых) подмассива A[p..q-1] и A[q+1..r]. Каждый элемент подмассива A[p..q-1] не превышает элемент A[q], а каждый элемент подмассива A[q+1..r] не меньше A[q]. Индекс q вычисляется в ходе выполнения процедуры.

#### Покорение.

Подмассивы A[p..q-1] и A[q+1..r] сортируются путем рекурсивного вызова процедуры быстрой сортировки.

#### Комбинирование.

Поскольку подмассивы сортируются на месте для их объединения не нужны никакие действия, весь массив A[p..r] оказывается отсортирован.

### QUICKSORT(A, p, r)

- 1. if p < r then
- 2.  $q \leftarrow PARTITION(A, p, r)$
- 3. QUICKSORT(A, p, q-1)
- 4. QUICKSORT(A, q+1, r)
- 5. end if

Для сортировки всего массива A, следует выполнить QUICKSORT(A, 1, length[A]).

- Процедура PARTITION изменяет порядок следования элементов подмассива A[p..r] без использования дополнительной памяти.
- Каждое разделение требует <sup>(n)</sup> операций.
- Количество шагов деления (глубина рекурсии) составляет приблизительно log n, если массив делится на более-менее равные части.

Таким образом, общее быстродействие: O (n log n), что и имеет место на практике.

Сортировка использует дополнительную память, так как приблизительная глубина рекурсии составляет O(log n), а данные о рекурсивных под вызовах каждый раз добавляются в стек.

### 3.3 Быстрая сортировка

### PARTITION(A, p, r)

- 1.  $x \leftarrow A[r]$
- 2.  $i \leftarrow p-1$
- 3. **for**  $j \leftarrow p$  **to** r 1 **do**
- 4. if  $A[j] \leq x$  then
- 5.  $i \leftarrow i + 1$
- 6. обменять  $A[i] \leftrightarrow A[j]$
- 7. end if
- 8. обменять  $A[i+1] \leftrightarrow A[r]$
- 9. **return** i + 1

#### Анализ.

Худший случай: набор входных данных, на которых алгоритм будет работать за  $O(n^2)$ .

Если каждый раз в качестве центрального элемента выбирается максимум или минимум входной последовательности.

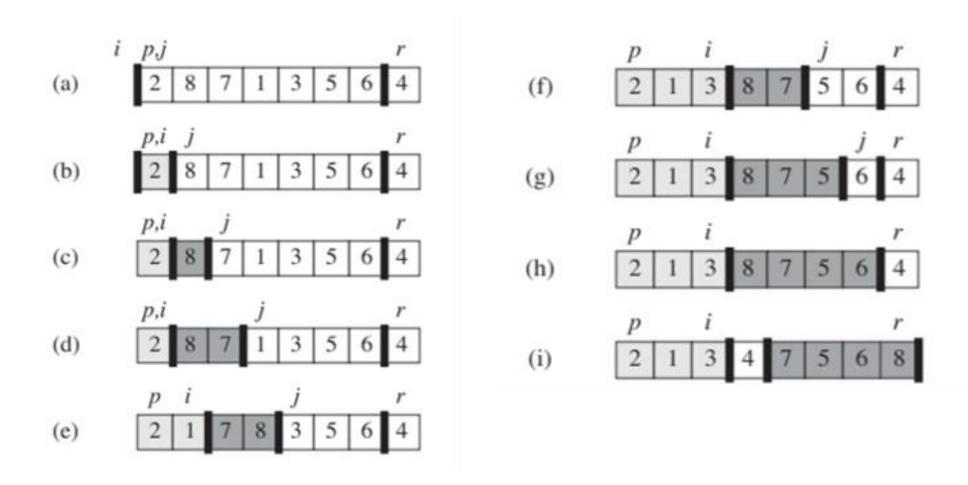
Если данные взяты случайно, вероятность этого равна  $2^n$ . И эта вероятность должна реализовываться на каждом шаге.  $\rightarrow$  малореальная ситуация.

### Метод неустойчив.

Поведение довольно естественно, если учесть, что при частичной упорядоченности повышаются шансы разделения массива на более равные части.

### 3.3 Быстрая сортировка

Разбиение массива. Пример действия процедуры PARTITION на массив, *опорный элемент r* 



### Общая схема быстрой сортировки:

- 1. из массива выбирается некоторый опорный элемент, например, x = a[r],
- 2. запускается процедура разделения массива, которая перемещает все ключи, меньшие, либо равные х, влево от него, а все ключи, большие, либо равные х вправо,
- 3. теперь массив состоит из двух подмножеств, причем левое содержит элементы меньшие, либо равные, элементов из правого,

$$A[p.q-1] x = A[q] A[q+1..r].$$

4. для обоих подмассивов: если в подмассиве более двух элементов, рекурсивно запускаем для него ту же процедуру.

В конце получится полностью отсортированная последовательность.

## 3.4 Сортировка Introsort или интроспективная сортировка

алгоритм сортировки, предложен Дэвидом Мюссером (англ.)рус. в 1997 году.

Использует быструю сортировку и переключается на пирамидальную сортировку, когда глубина рекурсии превысит некоторый заранее установленный уровень (например, логарифм от числа сортируемых элементов).

Подход сочетает в себе достоинства обоих методов с худшим случаем O(nlogn). и быстродействием, сравнимым с быстрой сортировкой.

Оба алгоритма используют сравнения, этот алгоритм также принадлежит классу сортировок на основе сравнений.

В быстрой сортировке одна из критичных операций — выбор опоры (элемент, относительно которого разбивается массив).

Простейший алгоритм выбора опоры — взятие первого или последнего элемента массива за опору - плохим поведение на отсортированных или почти отсортированных данных.

Никлаус Вирт - предложил серединный элемент для предотвращения этого случая, деградирующего до  $O(n^2)$  при неудачных входных данных.

Алгоритм выбора опоры «медиана трёх» выбирает опорой средний из первого, среднего и последнего элементов массива.

Это хорошо на большинстве входных данных, но можно найти такие входные данные, которые сильно замедлят этот алгоритм сортировки.

Злоумышленники: могут посылать такой массив Веб-серверу, добиваясь отказа в обслуживании.

В быстрой сортировке одна из критичных операций — выбор опоры (элемент, относительно которого разбивается массив).

Простейший алгоритм выбора опоры — взятие первого или последнего элемента массива за опору - плохим поведение на отсортированных или почти отсортированных данных.

Никлаус Вирт - предложил серединный элемент для предотвращения этого случая, деградирующего до  $O(n^2)$  при неудачных входных данных.

Алгоритм выбора опоры «медиана трёх» выбирает опорой средний из первого, среднего и последнего элементов массива. Это хорошо на большинстве входных данных, но можно найти такие входные данные, которые сильно замедлят этот алгоритм сортировки.

Злоумышленники: могут посылать такой массив Веб-серверу, добиваясь отказа в обслуживании.

# 3.5 Сортировка слиянием.

Метод декомпозиции («разделяй и властвуй»)

#### Идея метода:

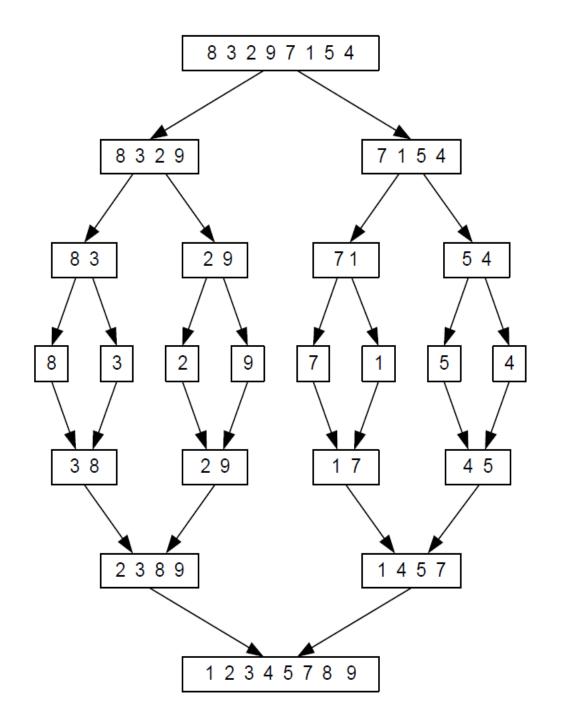
Разделим массив пополам,

Рекурсивно отсортируем части,

После чего выполним процедуру слияния: поддерживаем два указателя, один на текущий элемент первой части, второй — на текущий элемент второй части. Из этих двух элементов выбираем минимальный, вставляем в ответ и сдвигаем указатель...

Слияние - O(n), уровней -  $log n \rightarrow O(nlog n)$ .

### 3.5 Сортировка слиянием



# 3.6 Сортировка деревом

#### Идея метода:

- 1. Из сортируемых элементов строим двоичное дерево поиска.
- 2. Выполняем инфиксный обход дерева и получаем отсортированный массив.

Если строить сбалансированное дерево (красно-черное дерево),

То в худшем, среднем и лучшем случае: O(n logn)

# 3.7 Сортировка Timsort

Timsort — разработан в 2002 году Тимом Петерсом.

Стандартный алгоритмом сортировки в Python.

Часто сортируемый массив данных часто содержат в себе упорядоченные (не важно, по возрастанию или по убыванию) подмассивы. На таких данных Timsort эффективен.

Сложность алгоритма - O(nlogn).

Дополнительная память - O(n)

Timsort — это эффективная комбинация нескольких других алгоритмов и собственных идей.

### Суть алгоритма:

- 1. По специальному алгоритму разделяем входной массив на подмассивы.
- 2. Сортируем каждый подмассив обычной сортировкой вставками.
- 3. Собираем отсортированные подмассивы в единый массив с помощью модифицированной сортировки слиянием.

# 4. Внешняя сортировка

### Применяются к данным, хранящимся

- во внешней памяти
- на внешних устройствах последовательного доступа
- в каждый момент времени доступен только один компонент данных

Внешняя сортировка - это сортировка данных, которые расположены на внешних устройствах и не вмещающихся в оперативную память.

### Наиболее известны алгоритмы:

- сортировки слиянием (простое слияние и естественное слияние);
- улучшенные сортировки (многофазная сортировка и каскадная сортировка).

*Серия* (упорядоченный отрезок) — последовательность элементов, которая упорядочена по ключу.

Длина серии - количество элементов в серии.

Серия, состоящая из одного элемента - упорядочена.

Последняя серия может иметь длину меньшую, чем остальные серии.

Максимальное количество серий в файле - N (все элементы не упорядочены).

Минимальное количество серий - 1 (все элементы упорядочены).

**Распределение** — процесс разделения упорядоченных серий на два и несколько вспомогательных файлов.

*Фаза* − действия по однократной обработке всей последовательности элементов.

**Двухфазная сортировка** — сортировка, в которой отдельно реализуется две фазы: распределение и слияние.

*Однофазная сортировка* — сортировка, в которой объединены фазы распределения и слияния в одну.

4. Внешняя сортировка

**Двухпутевое слияние** - сортировка, в которой данные распределяются на два вспомогательных файла.

*Многопутевое слияние* - сортировка, в которой данные распределяются на N (N > 2) вспомогательных файлов.

Основные характеристики сортировки слиянием:

- количество фаз в реализации сортировки;
- количество вспомогательных файлов, на которые распределяются серии.

#### 4. Внешняя сортировка

# Сортировка простым слиянием –

```
Основана на процедуре слияния серией. Длина серий фиксируется на каждом шаге. В исходном файле все серии имеют длину 1, после первого шага она равна 2, после второго — 4, \ldots после \mathbf{k} -го шага — \mathbf{2}^{\mathbf{k}}.
```

# Сортировка двухпутевым (f1, f2) двухфазным (распределение, слияние) простым слиянием

Исходный файл **f**: **3 2 4 5 6 9 8 7 1** 

	Распределение	Слияние
1 проход	f1: <mark>3                                   </mark>	f: <mark>23                                   </mark>
2 проход	f1: <mark>2 3 6 9</mark> 1 f2 <mark>: 4 5 7 8</mark>	f: <mark>2345 <mark>6789</mark> 1</mark>
3 проход	f1: <mark>2 3 4 5</mark> 1 f2: <mark>6 7 8 9</mark>	f: <mark>23456789</mark> 1
4 проход	f1: <mark>2 3 4 5 6 7 8 9</mark> f2: <mark>1</mark>	f: <mark>1 2 3 4 5 6 7 8 9</mark>

# Алгоритм сортировки простым слиянием

Шаг 1. Исходный файл f разбивается на два вспомогательных файла f1 и f2.

Шаг 2. Вспомогательные файлы f1 и f2 сливаются в файл f, при этом одиночные элементы образуют упорядоченные пары.

Шаг 3. Полученный файл f вновь обрабатывается, как указано в шагах 1 и 2. При этом упорядоченные пары переходят в упорядоченные четверки.

Шаг 4. Повторяя шаги, сливаем четверки в восьмерки и т.д., каждый раз удваивая длину слитых последовательностей до тех пор, пока не будет упорядочен целиком весь файл

4. Внешняя сортировка

После выполнения і проходов получаем два файла, состоящих из серий длины 2і. Окончание процесса происходит при выполнении условия 2і>=n.

Процесс сортировки простым слиянием требует порядка O(log n) проходов по данным.

Признаками конца сортировки простым слиянием являются следующие условия:

- длина серии не меньше количества элементов в файле (определяется после фазы слияния);
- количество серий равно 1 (определяется на фазе слияния).
- при однофазной сортировке второй по счету вспомогательный файл после распределения серий остался пустым.

# Сортировка естественным слиянием –

Основана на процедуре слияния серий.

При естественном слиянии длина серий не ограничивается, а определяется количеством элементов в уже упорядоченных подпоследовательностях, выделяемых на каждом проходе.

### 4. Внешняя сортировка

# Сортировка двухпутевым (f1, f2) двухфазным (распределение, слияние) <u>естественным</u> слиянием

Исходный файл **f**: <mark>89</mark> **345 21 67** 

	Распределение	Слияние
1 проход	f1: <mark>8 9</mark> ' <mark>2</mark> <mark>'6 7</mark>	f: <mark>3 4 5 8 9</mark>
	f2 <mark>: 3 4 5 <mark>'1</mark></mark>	1. 3 7 3 6 3 1 2 6 7
2 прохоо	f1 <mark>: 3 4 5 8 9</mark> ' <mark>6 7</mark>	f: <mark>1 2 3 4 5 8 9</mark> ' <mark>67</mark>
	f2: <mark>1 2</mark>	1. 1 2 3 4 3 8 9 07
3 проход	f1: <mark>1 2 3 4 5 8 9</mark>	f: <mark>1 2 3 4 5 6 7 8 9</mark>
	f2 <mark>: 6 7</mark>	1.123430769

# Алгоритм сортировки естественным слиянием

Шаг 1. Исходный файл f разбивается на два вспомогательных файла f1 и f2. Распределение происходит следующим образом: поочередно считываются записи  $a_i$  исходной последовательности (неупорядоченной) таким образом, что если значения ключей соседних записей удовлетворяют условию  $f(a_i) <= f(a_{i+1})$ , то они записываются в первый вспомогательный файл f1. Как только встречаются  $f(a_i) > f(a_{i+1})$ , то записи  $a_{i+1}$  копируются во второй вспомогательный файл f2. Процедура повторяется до тех пор, пока все записи исходной последовательности не будут распределены по файлам.

Шаг 2. Вспомогательные файлы £1 и £2 сливаются в файл £, при этом серии образуют упорядоченные последовательности.

Шаг 3. Полученный файл f вновь обрабатывается, как указано в шагах f и f 2.

Шаг 4. Повторяя шаги, сливаем упорядоченные серии до тех пор, пока не будет упорядочен целиком весь файл.

Символ "`" обозначает признак конца серии.

Признаками конца сортировки естественным слиянием являются следующие условия:

- количество серий равно 1 (определяется на фазе слияния).
- при однофазной сортировке второй по счету вспомогательный файл после распределения серий остался пустым.

Естественное слияние, у которого после фазы распределения количество серий во вспомогательных файлах отличается друг от друга не более чем на единицу, называется *сбалансированным слиянием*, в противном случае – *несбалансированное слияние*.

4. Внешняя сортировка

**Число чтений или перезаписей файло**в при использовании метода естественного слияния будет **не хуже**, чем при применении метода простого слияния, а в среднем — даже лучше.

#### HO

- увеличивается число сравнений за счет тех, которые требуются для распознавания концов серий.
- максимальный размер вспомогательных файлов может быть близок к размеру исходного файла, так как длина серий может быть произвольной

